

# 概率论与数理统计

[Somnia1337](#)

## 1 概率论基础知识

### 概率及性质

💡 概率：

- 非负性：  $P(A) \geq 0$ 。
- 规范性：  $P(\Omega) = 1$ 。
- 可列可加性：对两两互斥的可列个事件，  $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$ 。

🔔 概率：

- $P(A - B) = P(A\bar{B}) = P(A) - P(AB)$ 。
- $P(A \cup B) = P(A) + P(B) - P(AB)$ 。

### 等可能概型

#### 古典概型

💡 古典概型：

- 试验的可能结果有限。
- 每个可能结果出现的可能性相等。

💡 古典概率：  $P(A) = \frac{k}{n} = \frac{A \text{ 中的样本点数}}{\Omega \text{ 中的样本点数}}$ 。

💡 超几何概率：  $N$  个球，其中  $m$  个为红球、其余为白球，取  $n$  球，其中恰有  $k$  个红球的概率为  $p_k = \frac{C_m^k C_{N-m}^{n-k}}{C_N^n}$ 。

#### 几何概型

💡 几何概型：试验的所有可能结果等可能地出现在一个有界的欧式区域  $\Omega$  内。

💡 几何概率：  $P(A) = \frac{m(A)}{m(\Omega)}$ ，其中  $m(A)$  为  $A$  的度量（长度 / 面积 / 体积）。

# 条件概率

◆ **条件概率**：在  $B$  发生的条件下  $A$  发生的概率称为  $B$  发生条件下  $A$  发生的条件概率，简称  $A$  对  $B$  的条件概率，记为  $P(A|B) = \frac{P(AB)}{P(B)}$ 。

📌 设  $A_1, \dots, A_n$  为  $\Omega$  的一个完备事件组， $B$  为任一事件：

- **乘法公式**：  $P(AB) = P(B)P(A|B) = P(A)P(B|A)$ 。
- **全概率公式**：  $P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$ 。
- **贝叶斯公式**：  $P(B) > 0$  时，

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{P(B)} = \frac{P(A_i)P(B|A_i)}{\sum_{j=1}^n P(A_j)P(B|A_j)}$$

## 事件的独立性

🔔 **独立**：若  $0 < P(B) < 1$ ，则  $A$  与  $B$  相互独立  $\iff P(A|B) = P(A|\bar{B})$ 。

◆ **独立试验**：将随机试验  $E$  重复进行  $n$  次，若各次试验的结果互不影响，称其为  $n$  重独立试验。

◆ **伯努利试验**：对一个  $n$  重独立试验，如果每次试验的可能结果只有“成功” / “失败”，称其为  $n$  重伯努利试验，称相应的数学模型为**伯努利概型**。

◆ **二项概率**：在  $n$  重伯努利试验中，设  $A$  在各次试验中发生的概率为  $p$ ，则  $A$  恰好发生  $k$  次的概率为  $P_n(k) = C_n^k p^k (1-p)^{n-k}$ 。

◆ **多项概率**：在  $n$  重独立试验中，每次试验的可能结果为  $A_1, \dots, A_k$ ，且  $0 < p_i = P(A_i) < 1$ ， $\sum_{i=1}^k p_i = 1$ ，则  $A_1, \dots, A_k$  各发生  $r_1, \dots, r_k$  次的概率为  $\frac{n!}{r_1! \dots r_k!} p_1^{r_1} \dots p_k^{r_k}$ 。

## 2 随机变量及其分布

### 随机变量

◆ **随机变量**：对一个试验的每个样本点  $\omega \in \Omega$ ，规定一个实数  $X(\omega)$ ，由此得到一个定义域为  $\Omega$  的实值函数  $X = X(\omega)$ ，称  $X$  为随机变量。

◆ **分布函数**：  $F(x) = P(X \leq x)$ 。

🔔 分布函数：非减，极限，右连续.

- 对任意  $x_1 < x_2$ ,  $F(x_1) \leq F(x_2)$ , 即  $F(x)$  非递减.
- $F(-\infty) = 0$ ,  $F(+\infty) = 1$ .
- 对任意  $x_0$ ,  $F(x_0) = F(x_0 + 0)$ , 即  $F(x)$  右连续.
- 对任意  $x_0$ ,  $P(X = x_0) = F(x_0) - F(x_0 - 0)$ .

## 离散型随机变量

💠 离散型随机变量：可能的取值数量为有限或可数无穷的随机变量.

💠 概率分布：离散型随机变量  $X$  可能的取值为  $x_1, \dots, x_n$ , 称  $X$  取各值的概率  $p_k = P(X = x_k)$  为  $X$  的概率分布（概率函数 / 分布律）. 概率分布可用表格 / 矩阵 / 图表表示.

- 表格：

$X$	$x_1$	$x_2$	$\cdots$	$x_n$
$p_k$	$p_1$	$p_2$	$\cdots$	$p_n$

- 矩阵：

$$X \sim \begin{pmatrix} x_1 & x_2 & \cdots & x_n \\ p_1 & p_2 & \cdots & p_n \end{pmatrix}$$

🔔 概率分布：这 2 条性质为概率分布的特征.

- 对任意  $k$ ,  $p_k \geq 0$ .
- $\sum_k p_k = 1$ .

💠 可列重伯努利试验：可一直重复下去的  $n$  重伯努利试验. 在成功概率为  $p$  的可列重伯努利试验中，首次“成功”出现在第  $k$  次试验中的概率  $p_k = p(1-p)^{k-1}$ .

💠 常见离散型分布：

- 几何分布：  $X \sim G(p)$ ,  $p_k = P(X = k) = p(1-p)^{k-1}$ .
- 超几何分布：  $X \sim H(n, m, N)$ ,  $p_k = P(X = k) = \frac{C_m^k C_{N-m}^{n-k}}{C_N^n}$ .
- 二项分布：  $X \sim B(n, p)$ ,  $P_n(k) = P(X = k) = C_n^k p^k (1-p)^{n-k}$ .
  - 0-1 分布：  $B(1, p)$ ,  $P(X = k) = p^k (1-p)^{1-k}$ .
  - 最可能次数：
    - 若  $(n+1)p$  为整数,  $k_0 = (n+1)p$  及  $(n+1)p - 1$ .

- 若  $(n+1)p$  不为整数,  $k_0 = [(n+1)p]$ .
- **泊松分布**:  $X \sim P(\lambda)$ ,  $P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}$ .
  - $p \leq 0.1$ ,  $n \geq 50$  的二项分布可近似为  $\lambda = np$  的泊松分布.

## 连续型随机变量

◆ **连续型随机变量**:  $F(x)$  为随机变量  $X$  的分布函数, 如果存在一个非负函数  $f(x)$ , 使得对任意实数  $x$ , 有

$$F(x) = \int_{-\infty}^x f(t) dt$$

称  $X$  为连续型随机变量, 称  $f(x)$  为  $X$  的**概率密度函数** (**密度函数 / 密度**).

🔔 **密度函数**: 这 2 条性质为密度函数的特征.

- $f(x) \geq 0$ ,  $x \in (-\infty, +\infty)$ .
- $\int_{-\infty}^{+\infty} f(x) dx = 1$ .

🔵  $X$  为连续型随机变量,  $F(x)$  为分布函数,  $f(x)$  为密度函数:

- 对任意常数  $a < b$ , 有  $P(a < X \leq b) = \int_a^b f(x) dx$ .
- 对任意常数  $C$ , 有  $P(X = C) = 0$ .
- $F(x)$  连续.
- 在  $f(x)$  的连续点, 有  $F'(x) = f(x)$ .

◆ **常见连续型分布**:

**均匀分布**:  $X \sim U(a, b)$ ,

- 密度函数:  $f(x) = \frac{1}{b-a}$ ,  $a \leq x \leq b$ .
- 分布函数:  $F(x) = \frac{x-a}{b-a}$ ,  $a \leq x \leq b$ .

**指数分布**:  $X \sim e(\lambda)$ ,

- 密度函数:  $f(x) = \lambda e^{-\lambda x}$  ( $\lambda > 0$ ),  $x > 0$ .
- 分布函数:  $F(x) = 1 - e^{-\lambda x}$ ,  $x > 0$ .

**$\Gamma$  分布**:  $X \sim \Gamma(\alpha, \beta)$ ,

- $\Gamma$  函数:  $\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$ .
  - $\Gamma(\alpha+1) = \alpha \Gamma(\alpha)$ .

- $\Gamma(1) = 1, \Gamma(\frac{1}{2}) = \sqrt{\pi}.$
- 对正整数  $n, \Gamma(n) = (n-1)!$ .
- 密度函数:  $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}.$

## 3 多维随机变量及其分布

### 二维随机变量

💡 **二维随机变量**: 设  $X, Y$  为定义在同一样本空间  $\Omega$  上的两个随机变量, 称  $(X, Y)$  为二维随机变量。

💡 **二维分布函数**: 称  $F(x, y) = P(X \leq x, Y \leq y)$  为  $(X, Y)$  的二维分布函数 / 联合分布函数。

🔔 二维分布函数:

- $F(x, y)$  分别关于  $x, y$  单调不减。
- $F(x, y)$  分别关于  $x, y$  右连续。
- $F(-\infty, -\infty) = F(-\infty, y) = F(x, -\infty) = 0, F(+\infty, +\infty) = 1.$
- 对任意  $x_1 < x_2, y_1 < y_2$ , 有  

$$F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) + F(x_1, y_1) \geq 0.$$

💡 **二维离散型随机变量**: 只取有限个或可数无穷个点对  $(x_i, y_i)$  的  $(X, Y)$ 。

💡 **二维概率分布**: 记  $p_{ij} = P(X = x_i, Y = y_j)$  为  $(X, Y)$  的二维概率分布 / 联合概率分布。

🔔 二维概率分布:

- $p_{ij} \geq 0.$
- $\sum p_{ij} = 1.$

💡 **二维连续型随机变量**:

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

则称  $(X, Y)$  为二维连续型随机变量, 称  $f(x, y)$  为 **二维概率密度函数 / 联合密度函数**。

🔔 二维密度函数:

- $f(x, y) \geq 0, (x, y) \in \mathbf{R}^2$ 。
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$ 。

二维连续型随机变量：(X, Y) 的密度函数为  $f(x, y)$ ,

- $F(x, y)$  连续, 且在  $f(x, y)$  的连续点  $(x, y)$  有  $f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$ 。
- 对平面上任意区域  $G \subset \mathbf{R}^2$ , 若  $f(x, y)$  在  $G$  上可积, 有  $P((X, Y) \in G) = \iint_G f(x, y) dx dy$ 。
- 对平面上任意一条曲线  $L$ , 有  $P((X, Y) \in L) = 0$ 。

## 边缘分布

## 条件分布

## 二维随机变量函数的分布

卷积公式：  $Z = X + Y$ ,

- $f_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx = \int_{-\infty}^{+\infty} f(z-y, y) dy$ 。
- 如果  $X$  与  $Y$  独立,  $f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx = \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) dy$ 。

## 4 随机变量的数字特征

$X$	$E(X)$	$D(X)$
$B(n, p)$	$np$	$np(1-p)$
$P(\lambda)$	$\lambda$	$\lambda$
$\Gamma(\alpha, \beta)$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$
$e(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
$U(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

## 数学期望

数学期望：

- 对离散型随机变量  $X$ , 概率分布  $P(X = x_k) = p_k$ , 如果级数  $\sum x_k p_k$  绝对收敛, 称其为  $X$  的数学期望。

- 对连续型随机变量  $X$ , 密度  $f(x)$ , 如果反常积分  $\int_{-\infty}^{+\infty} xf(x)dx$  绝对收敛, 称其为  $X$  的数学期望。

🔔 数学期望:

- $E(X \pm Y) = E(X) \pm E(Y)$  (线性性, 不依赖于独立性)。
- $E(XY) = E(X)E(Y)$  ( $X$  和  $Y$  独立)。

## 方差

💡 **方差**: 如果期望  $E[X - E(X)]^2$  存在, 称其为  $X$  的方差, 计算式为  $D(X) = E(X^2) - [E(X)]^2$ 。

🔔 方差:

- $D(aX + b) = a^2 D(X)$ 。
  - eg.  $D(-2X + 1) = 4D(X)$ 。
- 如果  $X$  和  $Y$  独立,
  - $D(X \pm Y) = D(X) + D(Y)$ 。
  - $D(XY) = D(X)D(Y) + [E(X)]^2 D(Y) + [E(Y)]^2 D(X)$ 。

💡 **变异系数**: 称  $C_v = \frac{\sqrt{D(X)}}{|E(X)|}$  为  $X$  的变异系数。

💡 矩:

- **原点矩**: 称  $m_k = E(X^k)$  为  $X$  的  $k$  阶原点矩。
- **中心矩**: 称  $\mu_k = E[X - E(X)]^k$  为  $X$  的  $k$  阶中心矩。

## 协方差

💡 **协方差**: 称  $\text{Cov}(X, Y) = E[(X - E(X))[Y - E(Y)]]$  为  $(X, Y)$  的协方差, 计算式  $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$ 。

🔔 协方差:

- $\text{Cov}(X, X) = D(X)$ 。
- $\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$ 。
- $\text{Cov}(X \pm Y, Z) = \text{Cov}(X, Z) \pm \text{Cov}(Y, Z)$ 。
- $D(X \pm Y) = D(X) + D(Y) \pm 2\text{Cov}(X, Y)$ 。
- $\text{Cov} > 0$  正线性相关,  $\text{Cov} < 0$  负线性相关,  $\text{Cov} = 0$  无线性相关。
  - $X$  与  $Y$  独立  $\implies \text{Cov}(X, Y) = 0$ 。

💡 **均值向量**: 称向量  $(E(X), E(Y))$  为  $(X, Y)$  的均值向量。

💡 **协方差阵**: 称矩阵  $\mathbf{V} = \begin{pmatrix} D(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & D(Y) \end{pmatrix}$  为  $(X, Y)$  的协方差阵。

## 相关系数

💡 **标准化随机变量**: 称  $X^* = \frac{X - E(X)}{\sqrt{D(X)}}$  为  $X$  的标准化随机变量。

🔔 标准化随机变量:  $E(X^*) = 0, D(X^*) = 1$ 。

💡 **相关系数**: 称  $R(X, Y) = \text{Cov}(X^*, Y^*)$  为  $X$  和  $Y$  的相关系数, 计算式  $R(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$ 。

🔔 相关系数:

- $|R(X, Y)| \leq 1$ 。
- $|R(X, Y)| = 1 \iff$  存在常数  $a \neq 0, b$ , 使  $P(Y = aX + b) = 1$ 。
- $R(X, Y) = 1$  完全正线性相关,  $R(X, Y) = -1$  完全负线性相关,  $R(X, Y) = 0$  不相关。
  - 独立  $\implies$  不相关, 但不相关是指没有线性相关关系, 可能有其他相关关系。

## 5 正态分布与自然指数分布族

### 正态分布

💡 **标准正态分布**: 记为  $N(0, 1)$ ,

- 密度函数

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

- 分布函数

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

💡 **正态分布**: 记为  $N(\mu, \sigma^2)$ , 满足  $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$ , 分布函数

$$F(x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$



$3\sigma$  原则:  $X$  落在  $(\mu - 3\sigma, \mu + 3\sigma)$  的概率为 0.9974, 因此常将该区间作为  $X$  的实际取值区间。

🔔 正态分布:  $X \sim (\mu, \sigma^2)$ ,

- $\Phi(x)$ 
  - $\Phi(0) = \frac{1}{2}$
  - $\Phi(x) + \Phi(-x) = 1$
  - 无法表示为初等函数
- $\phi(x)$ 
  - 关于  $x = \mu$  对称
  - 顶点为  $\max\{f(x)\} = \frac{1}{\sqrt{2\pi}} \sigma$
  - $\sigma$  越小, 分布越集中, 曲线越“瘦高”
- $E(X) = \mu, D(x) = \sigma^2$
- $Y = aX + b \sim N(a\mu + b, a^2\sigma^2)$

🔔 正态分布的可加性:  $n$  个正态分布  $X_i \sim N(\mu_i, \sigma_i^2)$  独立, 有

$$Z = \sum C_i X_i \sim N(\sum C_i \mu_i, \sum C_i^2 \sigma_i^2)$$

推论:  $n$  个变量  $X_i$  独立同分布于  $N(\mu, \sigma^2)$ , 有

$$\bar{X} = \frac{1}{n} \sum X_i \sim N(\mu, \frac{\sigma^2}{n})$$

## 二维正态分布

🔔 二维正态分布: 设二维随机变量  $(X, Y)$  有密度函数

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-r^2}} e^{-\frac{1}{2(1-r^2)} \left[ \frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} - 2r \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} \right]}$$

, 称  $(X, Y)$  服从二维正态分布, 记为  $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; r)$ 。

🔔 二维正态分布:

- 如果  $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; r)$ ,
  - $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$
  - $X$  与  $Y$  独立  $\iff r = 0$
- $(X, Y)$  服从二维正态分布  $\iff X$  与  $Y$  的任意非零线性组合  $Z = aX + bY$  服从一维正态分布

# 6 极限定理

## 大数律

💡 切比雪夫不等式:

$$P(|X - E(X)| < \epsilon) \geq 1 - \frac{D(X)}{\epsilon^2}$$

🔵 **大数律**: 随机变量序列  $\{X_n\}$  中,  $E(X_n) = \mu_n$ ,  $D(X_n) = \sigma^2$ , 如果  $n \rightarrow \infty$  时有  $\sigma^2 \rightarrow 0$ , 则  $X_n - \mu_n \xrightarrow{P} 0$ 。

🔵 **切比雪夫大数律**: 对独立随机变量序列  $\{X_k\}$ , 如果  $E(X_k)$ ,  $D(X_k)$  存在且存在常数  $C$  使  $D(X_k) < C$ , 则

$$\frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \xrightarrow{P} 0$$

🔵 **辛钦大数律 (独立同分布大数律)**: 对独立同分布随机变量序列  $\{X_k\}$ ,  $E(X_k) = \mu$ ,  $D(X_k) = \sigma^2$ , 则

$$\bar{X} \xrightarrow{P} \mu$$

🔵 **伯努利大数律**: 在  $n$  次伯努利试验中, 事件  $A$  发生的频率为  $f_n(A) = \frac{n_A}{n}$ , 发生的概率为  $p = P(A)$ , 则

$$f_n(A) \xrightarrow{P} p = P(A)$$

## 中心极限定理

🔵 **独立同分布的中心极限定理**:  $n$  充分大时,  $n$  个独立同分布的随机变量之和近似服从正态分布, 即

$$\sum_{k=1}^n X_k \sim N(n\mu, n\sigma^2)$$

或

$$\frac{1}{n} \sum_{k=1}^n X_k \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

🔵 **二项分布的中心极限定理**:  $n$  充分大时,  $n$  个独立同分布的二项分布之和近似于正态分布, 即

$$X_n \sim N(np, np(1-p))$$

## 7 数理统计的基础知识

### $\chi^2$ 分布, $t$ 分布, $F$ 分布

💎  $\chi^2$  分布:  $X_1, \dots, X_n$  独立同服从  $N(0, 1)$ , 称

$$\chi^2 = \sum_{i=1}^n X_i^2$$

服从自由度为  $n$  的  $\chi^2$  分布, 记为  $\chi^2 \sim \chi^2(n)$ .

🔔  $\chi^2$  分布:

- $\chi^2(n)$  等同于  $\Gamma(\frac{n}{2}, \frac{1}{2})$ .
  - $\chi^2 \sim \chi^2(n) \Rightarrow E(\chi^2) = n, D(\chi^2) = 2n$ .
- 可加性:  $\chi^2(n_1) + \chi^2(n_2) \sim \chi^2(n_1 + n_2)$  (独立).

💎  $t$  分布:  $X \sim N(0, 1), Y \sim \chi^2(n)$ ,  $X$  与  $Y$  独立, 称

$$t = \frac{X}{\sqrt{Y/N}}$$

服从自由度为  $n$  的  $t$  分布, 记为  $t \sim t(n)$ .

🔔  $t$  分布:

- $n = 1$  时  $E(t)$  不存在,  $n \geq 2$  时  $E(t) = 0$ .
- $n$  充分大 ( $\geq 45$ ) 时,  $t(n)$  近似于  $N(0, 1)$ .
- $X \sim N(0, 1) \rightarrow -X \sim N(0, 1) \Rightarrow t \sim t(n) \rightarrow -t \sim t(n)$ .

💎  $F$  分布:  $X \sim \chi^2(n), Y \sim \chi^2(m)$ ,  $X$  与  $Y$  独立, 称

$$F = \frac{X/n}{Y/m}$$

服从自由度为  $(n, m)$  的  $F$  分布, 记为  $F \sim F(n, m)$ .

🔔  $F$  分布:  $F \sim F(n, m) \rightarrow \frac{1}{F} \sim F(m, n)$ .

💎  $p$  分位点:  $0 < p < 1$ , 称满足  $F(a_p) = P(X \leq a_p) = p$  的  $a_p$  为  $X$  的  $p$  分位点, 称  $a_{\frac{1}{2}}$  为中位数.

📌  $p$  分位点:

- $N(0, 1)$ :  $u_p = -u_{1-p}$ .
- $\chi^2(n)$ :
  - $n \leq 45$  时, 查表.
  - $n > 45$  时,  $\chi_p^2(n) \approx \frac{1}{2}(u_p + \sqrt{2n-1})^2$ .
- $t(n)$ :
  - $t_p = -t_{1-p}$ .
  - $n > 45$  时,  $t_p \approx u_p$ .
- $F(n, m)$ :  $F_p(n, m) = \frac{1}{F_{1-p}(m, n)}$ .

## 统计量

💡 **样本函数**: 样本  $X_1, \dots, X_n$  的连续函数  $g(X_1, \dots, X_n)$ .

💡 **统计量**: 不含未知参数的样本函数.

常用统计量:

- 均值:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- 方差:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- 标准差:

$$S = \sqrt{S^2}$$

- $k$  阶原点矩:

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

- $k$  阶中心矩:

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

均值  $\bar{X}$  为 1 阶原点矩  $A_1$ , 方差  $S^2$  不是 2 阶中心矩  $B_2$ .

# 抽样分布定理

## 一个正态总体

•  $X_i$  来自正态总体  $N(\mu, \sigma^2)$ :

- $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$
- $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$
- $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$
- $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$
- $\bar{X}$  与  $S^2$  独立.

•  $X_i$  来自任意总体  $X$ ,  $E(X) = \mu$ ,  $D(X) = \sigma^2$ , 且  $n$  充分大:

- $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$
- $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim N(0, 1)$

## 两个正态总体

• 两个总体  $X \sim N(\mu_1, \sigma_1^2)$ ,  $Y \sim N(\mu_2, \sigma_2^2)$ :

- $U = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$

- $$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

其中

$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

- $$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

## 8 参数估计

一个总体  $X$  的分布函数往往含有未知参数或未知参数向量  $\theta$ ，从而可记总体分布函数为  $F(x, \theta)$ 。

解决实际问题时需要了解未知参数或未知参数向量  $\theta$ ，因此可以利用样本提供的信息，对  $\theta$  有一个基本的估计，这就是参数的估计问题。

参数的估计问题分为点估计和区间估计两大类。

### 点估计

**点估计**： $X$  的分布函数为  $F(x, \theta)$ ，抽取样本  $X_1, \dots, X_n$ ，其观测值为  $x_1, \dots, x_n$ ，构造某个统计量，用其观测值  $\hat{\theta}(x_1, \dots, x_n)$  估计  $\theta$ ，称  $\hat{\theta}(x_1, \dots, x_n)$  为  $\theta$  的点估计值，称  $\hat{\theta}(X_1, \dots, X_n)$  为  $\theta$  的点估计量，点估计值或点估计量称为  $\theta$  的点估计，均可简记为  $\hat{\theta}$ 。

点估计分为矩估计、极大似然估计。

**矩估计**： $X$  的分布函数为  $F(x, \theta)$ ， $m = E(X)$  一般为  $\theta$  的函数，反解出  $\theta = g(m)$ ，用样本均值  $\bar{X}$  代替，得到  $\hat{\theta} = g(\bar{x})$  称为  $\theta$  的矩估计值。

**矩估计**： $X$  服从任何分布，记  $\mu = E(X)$ ， $\sigma^2 = D(X)$ ，有：

- $\hat{\mu} = \bar{X}$
- $\hat{\sigma}^2 = B_2$

**似然函数**：

- 离散型： $L(\theta) = \prod p(x_i, \theta)$

- 连续型:  $L(\theta) = \prod f(x_i, \theta)$

💡 **极大似然估计**: 如果存在  $\theta$  的一个取值  $\hat{\theta}(x_1, \dots, x_n) = \theta$ , 使得  $L(\hat{\theta}) = \max\{L(\theta)\}$ , 称  $\hat{\theta}$  为  $\theta$  的极大似然估计值, 由  $\frac{d(\ln L(\theta))}{d\theta} = 0$  求解。

## 估计量的评选标准

💡 **无偏估计量**: 如果  $\theta$  的估计量  $\hat{\theta}$  满足  $E(\hat{\theta}) = \theta$ , 称  $\hat{\theta}$  为无偏估计量。

💡 **渐进无偏估计量**: 称  $b(\hat{\theta}) = E(\hat{\theta}) - \theta$  为  $\hat{\theta}$  的 **偏差**, 如果样本容量  $n \rightarrow +\infty$  时,  $b(\hat{\theta}) \rightarrow 0$ , 称  $\hat{\theta}$  为渐进无偏估计量。

📌 **无偏估计量**:  $X$  服从任何分布,

- $\mu = E(X)$ , 样本均值  $\bar{X}$  为  $\mu$  的无偏估计量。
- $m_k = E(X^k)$ , 样本  $k$  阶矩  $A_k$  为  $m_k$  的无偏估计量。
- $\sigma^2 = D(X)$ , 样本方差  $S^2$  为  $\sigma^2$  的无偏估计量。

💡 **有效性**:  $\hat{\theta}_1, \hat{\theta}_2$  为  $\theta$  的无偏估计量, 如果  $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$ , 称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  更有效。

💡 **线性无偏估计**:  $\forall (a_i)$ , 如果  $\sum a_i = 1$ , 称  $\hat{\mu} = \sum a_i X_i$  为  $\mu$  的线性无偏估计。

样本均值  $\bar{X}$  是最有效的线性无偏估计。

## 区间估计

💡 **置信区间**:  $X$  的分布函数为  $F(x, \theta)$ ,  $\hat{\theta}_1, \hat{\theta}_2$  为统计量, 如果对给定概率  $1 - \alpha$ , 有  $P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$ , 称区间  $(\hat{\theta}_1, \hat{\theta}_2)$  为  $\theta$  的置信度为  $1 - \alpha$  的置信区间。

$\alpha$  越小, 置信度越高, 区间越宽 (误差越大)。

📌 一个正态总体下参数的置信区间:  $X \sim N(\mu, \sigma^2)$ ,

估计	已知	置信区间( $1 - \alpha$ )
$\mu$	$\sigma_0$	$(\bar{X} - u_{1-\frac{\alpha}{2}} \frac{\sigma_0}{\sqrt{n}}, \bar{X} + u_{1-\frac{\alpha}{2}} \frac{\sigma_0}{\sqrt{n}})$
	$s$	$(\bar{X} - t_{1-\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{1-\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}})$
$\sigma^2$	$s$	$(\frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)})$

单侧置信限:

- $\mu$  的置信度为  $1 - \alpha$  的单侧置信下限为  $\bar{X} - t_{1-\alpha}(n-1) \frac{S}{\sqrt{n}}$ 。

- $\sigma^2$  的置信度为  $1 - \alpha$  的单侧置信上限为  $\frac{(n-1)S^2}{\chi_{\alpha}^2(n-1)}$ 。

## 9 假设检验

### 假设检验

💡 假设检验（显著性检验）：

- **原假设**：  $H_0$ 。
- **备择假设**：  $H_1$ 。
- **显著性水平**： 很小的正数  $\alpha$ 。
- **检验统计量**： 服从已知分布的量，  $U / t / \chi^2$ 。
- **临界值**： 小概率事件发生的临界分位点。
- **拒绝域**： 小概率事件发生时检验统计量的值域。

### 正态总体下的假设检验

- $\sigma^2$  已知， 检验  $\mu$ ：  $U = \frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} \sim N(0, 1)$

$H_0$	$H_1$	拒绝域
$\mu = \mu_0$	$\mu \neq \mu_0$	$ U  > u_{1-\frac{\alpha}{2}}$
$\mu \leq \mu_0$	$\mu > \mu_0$	$U > u_{1-\alpha}$
$\mu \geq \mu_0$	$\mu < \mu_0$	$U < -u_{1-\alpha}$

- $\sigma^2$  未知， 检验  $\mu$ ：  $t = \frac{\bar{X} - \mu_0}{S / \sqrt{n}} \sim t(n - 1)$

$H_0$	$H_1$	拒绝域
$\mu = \mu_0$	$\mu \neq \mu_0$	$ t  > t_{1-\frac{\alpha}{2}}(n - 1)$
$\mu \leq \mu_0$	$\mu > \mu_0$	$t > t_{1-\alpha}(n - 1)$
$\mu \geq \mu_0$	$\mu < \mu_0$	$t < -t_{1-\alpha}(n - 1)$

- $\mu$  未知， 检验  $\sigma^2$ ：  $\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n - 1)$

$H_0$	$H_1$	拒绝域
$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi^2 < \chi_{\frac{\alpha}{2}}^2(n - 1), \chi^2 > \chi_{1-\frac{\alpha}{2}}^2(n - 1)$
$\sigma^2 \leq \sigma_0^2$	$\sigma^2 > \sigma_0^2$	$\chi^2 > \chi_{1-\alpha}^2(n - 1)$



$H_0$	$H_1$	拒绝域
$\sigma^2 \geq \sigma_0^2$	$\sigma^2 < \sigma_0^2$	$\chi^2 < \chi_\alpha^2(n-1)$